

LAPORAN DATA QUALITY AUDIT DAN PREPROCESSING PIPELINE

Data Mining KJ002 – Pertemuan 2 – Dataset Telco Customer Churn

Putri Sabrina Metekohy (20240801025) – Teknik Informatika, Fakultas Ilmu Komputer Dosen:

Ir. Nizirwan Anwar, MT, IPM

Kode dan notebook: https://github.com/Sabriputri/Tugas-Data-Mining-Pertemuan-2_Putri-Sabrina-Metekohy.git

1. Data Profile

Data yang saya gunakan berasal dari Telco Customer Churn, berisi 7.043 pelanggan dengan 21 kolom. Satu baris mewakili satu pelanggan. Isinya terdiri dari satu kolom identitas (customerID), satu kolom target (Churn), tiga kolom numerik kontinu (tenure, MonthlyCharges, TotalCharges), satu kolom biner (SeniorCitizen), serta lima belas kolom kategorikal, yaitu empat belas bersifat nominal dan satu ordinal (Contract).

2. Data Quality Problems

Dari proses audit di notebook, ada lima hal yang perlu ditangani sebelum data dipakai untuk pemodelan:

- **Tipe data salah.** TotalCharges terbaca sebagai teks karena 11 selnya hanya berisi spasi, sehingga sebenarnya merupakan nilai kosong yang tersembunyi (sekitar 0,16% data). Ke-11 baris itu semuanya memiliki tenure 0, jadi mereka adalah pelanggan baru yang belum pernah ditagih.
- **Kelas tidak seimbang.** Pelanggan yang bertahan berjumlah 5.174 (73,5%) dan yang berhenti 1.869 (26,5%), rasio sekitar 2,8 : 1. Model yang selalu menebak "bertahan" sudah meraih akurasi sekitar 73,5% tanpa menemukan satu pun pelanggan yang akan pergi.
- **Skala berbeda jauh.** tenure bernilai puluhan, sedangkan TotalCharges bisa mencapai ribuan.
- **Fitur belum numerik.** Lima belas kolom kategorikal masih berupa teks. Isian "No internet service" dan "No phone service" bukan missing, melainkan kategori sah yang berarti pelanggan tidak memiliki layanan tersebut.
- **Kolom identitas.** customerID unik untuk setiap pelanggan sehingga tidak ada pelanggan yang tercatat dua kali, tetapi kolom ini tidak membawa pola yang dapat digeneralisasi. Pemeriksaan baris kembar dilakukan setelah kolom ini dibuang. Baris yang kebetulan identik tetap dipertahankan, karena pelanggan yang berbeda bisa saja memiliki profil layanan yang sama.

3. Treatment

Masalah	Perlakuan
TotalCharges teks / kosong	Dikonversi dengan <code>pd.to_numeric(errors="coerce")</code> , lalu diisi median di dalam pipeline.

customerID	Dibuang dari fitur.
Pembagian data	Split stratified 80:20 (random_state = 42) dilakukan lebih dulu, sebelum transformasi apa pun.
Fitur nominal (14 kolom)	One-Hot Encoding dengan handle_unknown="ignore" dan drop="if_binary".
Contract (ordinal)	OrdinalEncoder dengan urutan Month-to-month, One year, Two year.
Skala numerik	StandardScaler pada tenure, MonthlyCharges, dan TotalCharges; fitur biner dan hasil one-hot tidak diubah.
Kelas tidak seimbang	class_weight="balanced" sebagai cara utama, SMOTE sebagai pembanding, keduanya hanya memengaruhi data latih.
Target	Churn dikodekan No = 0 dan Yes = 1.

4. Justification

Median dipilih untuk TotalCharges karena tidak mudah bergeser oleh nilai ekstrem, dan kebetulan 11 baris yang kosong itu memang pelanggan dengan tenure 0, sehingga mengisinya dengan 0 pun bisa dipertanggungjawabkan sebagai pembanding. One-Hot dipakai pada fitur nominal agar model tidak menganggap ada urutan di antara kategori yang sebenarnya setara, sementara Contract punya tingkat komitmen yang jelas sehingga cocok diberi kode berurutan.

Scaling penting untuk KNN, SVM, dan Logistic Regression. KNN menghitung jarak, sehingga fitur berskala besar mendominasi dan fitur lain nyaris tak berpengaruh. Pada Logistic Regression yang diregularisasi, skala yang timpang membuat penalti tidak adil dan konvergensi lebih lambat. Model berbasis tree tidak terlalu terpengaruh karena standardisasi tidak mengubah urutan nilai yang dipakai untuk menentukan titik pemisah.

SMOTE hanya boleh dijalankan pada data latih. Bila dijalankan sebelum data dibagi, titik-titik yang kelak menjadi data uji ikut dipakai untuk membuat sampel sintetis, sehingga model seolah sudah melihat soal ujiannya dan skornya menjadi terlalu optimis. Alasan yang sama berlaku untuk imputer, scaler, dan encoder: semuanya dipelajari dari data latih saja. Untuk itu seluruh langkah, termasuk SMOTE, dibungkus dalam satu pipeline sehingga pada cross-validation setiap fold diproses ulang secara terpisah dan risiko kebocoran data (leakage) tertutup.

Eksperimen kecil. KNN dan Logistic Regression dipakai hanya untuk melihat dampak preprocessing, bukan sebagai model akhir. Angka lengkap tiap skenario tersimpan di file hasil_eksperimen_B8.csv pada repositori GitHub; di sini dirangkum pengamatannya.

Kode	Kondisi	Pengamatan
A	Tanpa scaling	KNN memberi skor ROC-AUC yang lebih rendah karena jaraknya didominasi TotalCharges. Logistic Regression memerlukan iterasi jauh lebih banyak sampai konvergen.
B	StandardScaler	Skor KNN naik jelas, sedangkan skor Logistic Regression hampir tidak berubah tetapi konvergen dengan iterasi dan waktu yang jauh lebih sedikit.
C	Tanpa penanganan imbalance	Akurasi terlihat cukup baik, tetapi recall kelas churn rendah karena model cenderung menebak pelanggan akan bertahan.
D	class_weight / SMOTE	Recall churn naik tajam dengan harga precision dan akurasi yang turun. Kedua cara memberi hasil yang berdekatan, sedangkan ROC-AUC nyaris tidak berubah.

Pola ini sesuai harapan: scaling terutama membantu model berbasis jarak, sedangkan penanganan imbalance menukar sedikit precision dengan recall churn yang jauh lebih baik. Untuk kebutuhan

retensi, menjangkau pelanggan yang benar-benar berisiko lebih penting daripada sedikit tambahan salah sasaran.

5. Final Dataset Condition

Setelah seluruh langkah dijalankan, data latih berukuran 5.634 baris dengan 38 fitur (jumlah ini sebelum resampling; SMOTE menambah sampel sintetis hanya di dalam pipeline saat pelatihan), tidak memiliki missing value, semuanya bertipe numerik, dan fitur kontinu sudah berskala standar (rata-rata mendekati 0, simpangan baku 1). Data uji berukuran 1.409 baris, hanya ditransformasi dengan parameter dari data latih dan tidak di-resample, sehingga proporsi kelasnya tetap seperti aslinya. Seluruh proses dapat diulang dari awal melalui notebook pada repositori GitHub di atas.

6. Kesimpulan

Audit menunjukkan bahwa data Telco Customer Churn sudah cukup bersih, dengan masalah utama berupa satu kolom bertipe salah, kelas target yang timpang, dan fitur yang belum siap dipakai model. Semuanya dapat diatasi lewat satu pipeline yang urutannya jelas: bagi data lebih dulu, pelajari semua parameter transformasi hanya dari data latih, lalu terapkan ke data uji.

Pelajaran terpenting dari tugas ini adalah bahwa skor yang tampak bagus belum tentu jujur. Scaling, imputasi, maupun SMOTE yang dijalankan sebelum pembagian data bisa menaikkan skor tanpa membuat model benar-benar lebih baik. Dengan membungkus semuanya dalam pipeline, hasil evaluasi lebih mencerminkan kondisi pelanggan sesungguhnya dan prosesnya mudah diulang oleh siapa pun yang membuka repositori di atas.